

Cloud & Mobile 2026 – Homework 2

FABIO GIOVANNI TOMASONI, MATRICOLA 1091999

SIMONE GATTI, MATRICOLA 1091998

Link GitHub:

https://github.com/fabiotomasoni/cloud_mobile_2026_shorted

Link Trello:

<https://trello.com/b/jYELzvY/piattaforme-cloud-e-applicazioni-mobili-shorted>

MyTEDx – COME TRATTARE IL DATASET WATCH NEXT



Il file contiene le associazioni tra un talk principale e i talk suggeriti tramite i loro ID



Nel DWH vogliamo costruire un modello aggregato in cui salvare queste informazioni



Trasformiamo le associazioni ID nel file .csv in array annidati nel nostro Database

COME ABBIAMO MODIFICATO IL JOB PYSPARK



La modifica consiste nell'aggiungere anche la lettura del dataset dei talk suggeriti



Il dataset viene letto nello stesso modo degli altri .csv



Abbiamo aggregato per ID usando la stessa logica già usata per i tag




A differenza dei tag in cui raccogliamo una lista semplice di stringhe, per watch_next raccogliamo una lista di oggetti strutturati.



Infine il dataset aggregato viene aggiunto al modello finale con una nuova join (e scritto in MongoDB)

```
▼ tags : Array (4)
  0: "science"
  1: "communication"
  2: "personal growth"
  3: "TEDx"
tch_next : Array (6)
  0: Object
    related_id : "2883"
    slug : "helen_pearson_lessons_from_the_longest_study_on_human_development"
    title : "Lessons from the longest study on human development"
    duration : "736"
    viewedCount : "3028411"
    presenterDisplayName : "Helen Pearson"
  ▼ 1: Object
    related_id : "145825"
    slug : "michael_bungay_stanier_how_to_tame_your_advice_monster_feb_2025"
    title : "How to tame your advice monster"
    duration : "847"
    viewedCount : "292255"
    presenterDisplayName : "Michael Bungay Stanier"
  ▼ 2: Object
    related_id : "144704"
    slug : "margaux_miller_6_ways_to_make_better_connections_online"
    title : "6 ways to make better connections online"
    duration : "671"
    viewedCount : "338341"
    presenterDisplayName : "Margaux Miller"
  ▼ 3: Object
    related_id : "1592"
    slug : "melissa_marshall_talk_nerdy_to_me"
    title : "Talk nerdy to me"
    duration : "257"
    viewedCount : "3003971"
```

UTILIZZO E FUNZIONALITÀ WATCH_NEXT



ShorTED – Elaborazione Dati



Abbiamo scaricato i transcript dai video presenti nel dataset



Abbiamo caricato i transcript e il dataset in un bucket S3 chiamato «raw-data»



Con un job PySpark abbiamo processato i dati aggregandoli in un file JSON strutturato per ogni video



I file JSON sono stati caricati nel bucket S3 «processed-data»

ShorTED – Job PySpark



Il job PySpark ha
l'obiettivo di
trasformare i dati
grezzi in un file JSON
strutturato per ogni
talk



Il job legge i dati dal
bucket S3 «raw-data»



Aggrega i dati usando
come chiave l'ID del
dataset




Genera un JSON con
schema finale
mostrato
nell'immagine



Carica i JSON nel
bucket S3
«processed-data»

```
{
  "id": 1,
  "title": "Example Transcript",
  "slug": "example-transcript",
  "url": "https://example.com/transcripts/example-transcript",
  "duration": 3600,
  "tags": ["example", "transcript"],
  "related_videos": [2,3],
  "presenterDisplayName": "John Doe",
  "speakers": ["John Doe", "Jane Smith"],
  "image": "https://example.com/image.jpg",
  "transcriptions": {
    "en": {
      "language": "English",
      "sentences": [
        {
          "timestamp": "7000",
          "text": "This is the first sentence of the transcript."
        },
        {
          "timestamp": "15000",
          "text": "This is the second sentence of the transcript."
        }
      ],
      "raw": "This is the full transcript in English."
    },
    "it": {
      "language": "Italian",
      "sentences": [
        {
          "timestamp": "7000",
          "text": "Questo è la prima frase della trascrizione."
        },
        {
          "timestamp": "15000",
          "text": "Questo è la seconda frase della trascrizione."
        }
      ],
      "raw": "Questo è la trascrizione completa in italiano."
    }
  }
}
```

Criticità affrontate



Possibili evoluzioni

PYSPARK:

- Verifica e validazione schema JSON finale
- Aggiornamenti incrementali

PROGETTO SHORTED

- I dati strutturati verranno usati dalla pipeline AI per generare gli «snacks»
- Gli «snacks» verranno caricati su MongoDB
- Il backend a cui si collega l'applicazione, prenderà gli «snacks» direttamente da MongoDB