

Cloud & Mobile 2026- Homework 3

Fabio Tomasoni, matricola 1091999

Simone Gatti, matricola 1091998

GitHub: https://github.com/fabiotomasoni/cloud_mobile_2026_shorted

Trello: <https://trello.com/b/jYELzvY/piattaforme-cloud-e-applicazioni-mobili-shorted>

MyTEDx

MyTEDx – Get_Watch_Next_by_Idx




Obiettivo

Evolvere il servizio permettendo all'utente di navigare attraverso talk suggeriti.




Data Strategy

Utilizzo di uno schema Mongoose ottimizzato che mappa i talk per tag (LF Get_Talks_By_Tag) e per ID (LF Get_Watch_Next_By_ID).




Infrastruttura

Sincronizzazione in tempo reale tra MongoDB e AWS.



MyTEDx – Get_Watch_Next_by_Idx




Lambda Deployment

Funzione in Node.js, configurazione DB connection e layer necessari per Mongoose.



Logica API


Numero risultati per pagina dinamico per gestire grandi volumi di dati.



Esposizione

Endpoint REST esposto via API Gateway e testato con Postman.

MyTEDx – Come Utilizzare Get_Watch_Next_by_Idx




Permettere all'utente di continuare l'esperienza nell'app suggerendo la visione di un video correlato quando finisce di vederne uno.



Creare la base di un algoritmo di suggestions per la home page



Migliorare il servizio stesso tenendo traccia di quante volte gli utenti cliccano e visualizzano un video consigliato





ShorTED — Ingestione tramite LF Dispatcher




S3 Paging

Scansione dei JSON tramite ListObjectV2Command per gestire grandi volumi di dati



Batching

Raggruppamento dei file in pacchetti da 10 per ottimizzare le chiamate a SQS




Runtime

Node.js per massimizzare la velocità di I/O durante il dispatching.



Disaccoppiamento

SQS funge da buffer, garantendo resilienza contro eventuali fallimenti.



ShorTED – Flusso completo AI pipeline



Ingestione

SQS riceve il messaggio; handler.py legge S3 processed e costruisce l'AIContext.



Idempotenza e lock

sourceHash, pipelineVersion e lock MongoDB decidono skip, ownership e retry sicuro.



AI + validazione


Bedrock genera i campi semantici; MCP e final_validator controllano qualità.



Persistenza

delete-before-insert su MongoDB; delete SQS solo dopo successo.

Percorso operativo




Guardrail: batch locale = 1, messaggi non riusciti restano in SQS, completati saltati salvo flag esplicito.

ShorTED – Output finale generato

```
{
  "_id": "isabel_allende...:seg_007",
  "segmentId": "seg_007",
  "talkId": "10005",
  "talkSlug": "isabel_allende_tales_of_passion",
  "speaker": "Isabel Allende",
  "talkTitle": "Tales of passion",
  "topic": "The Value of a Passionate Heart in Service",
  "quote": "Jenny has a brave and passionate heart...",
  "motivationalText": "Even when faced with lack of resources...",
  "aphorism": "Passion drives action even without perfect preparation.",
  "tags": ["service", "courage", "dedication"],
  "score": 0.85,
  "startTime": 717,
  "endTime": 721,
  "talkUrl": "https://www.ted.com/talks/... ?t=717",
  "language": "en",
  "aiPipelineVersion": "v1",
  "sourceHash": "c545a343..."
}
```

Documento MongoDB persistito dopo validazione finale



Identità deterministica

_id, segmentId, lingua e versione rendono il documento stabile e rigenerabile.



Contenuto per l'app

topic, quote, motivationalText, aphorism e tags alimentano la UX snack.



Grounding e qualità

score, startTime, endTime e talkUrl ancorano lo snack al segmento del talk.

ShorTED – MCP server, test e roadmap



MCP Server

Espone tools read-only, validatori e resources con schema snack, regole mixer e grounding.



Testing locale con Ollama

mcp_ollama_repl.py permette di testare localmente il funzionamento server MCP con modelli AI in Ollama



Esperienza utente

Il risultato è uno snack con quote, timing, tag e URL temporizzato pronto per ricerca e fruizione.



Criticità ed evoluzioni

Costi AI, qualità output, metriche e validazione

```
(.venv) gatti@Mac-mini TEDx % python3.14 scripts/AWS/ShorTED/MCP/shorted_mcp_server.py
INFO: Started server process [50194]
INFO: Waiting for application startup.
INFO:mcp.server.streamable_http_manager:StreamableHTTP session manager started
INFO: Application startup complete.
INFO: Uvicorn running on http://0.0.0.0:8080 (Press CTRL+C to quit)
INFO:mcp.server.streamable_http_manager:Created new transport with session ID: 0284405c154144794
74d339a4254fcb
INFO: 127.0.0.1:56911 - "POST /mcp HTTP/1.1" 200 OK
INFO: 127.0.0.1:56911 - "POST /mcp HTTP/1.1" 202 Accepted
INFO: 127.0.0.1:56911 - "POST /mcp HTTP/1.1" 200 OK
INFO:mcp.server.lowlevel.server:Processing request of type CallToolRequest

Comandi:
/help          mostra questa guida
/tools         lista i tool MCP esposti a Ollama
/call <tool> <json> chiama direttamente un tool MCP
/reset        azzerà la conversazione Ollama
/exit         esci

Esempi:
/call get_snack_schema {}
/call canonicalize_tags {"tags":["AI Ethics","Personal growth"]}

> mostrami lo schema degli snacks
[MCP] get_snack_schema
output:
{
  "description": "A single ShorTED snack - a meaningful, self-contained segment of a TED/TEDx talk.",
  "type": "object",
  "required": [
    "segmentId",
    "talkId",
    "talkSlug",
    "speaker",
    "talkTitle",
    "topic",
    "quote",
    "motivationalText",
    "aphorism",
    "tags",
    "score",
    "startTime",
    "endTime",
    "talkUrl",
    "language"
  ],
  "properties": {
    "segmentId": {
      "type": "string",
      "description": "Unique identifier for this segment within the talk. Formatted as: seg_001, seg_002, ...",
      "example": "seg_001"
    },
    "talkId": {
      "type": "string",
      "description": "Numeric ID of the talk (as string)."
    },
    "talkSlug": {
      "type": "string",
      "description": "URL-safe slug of the talk. Must match the talk being processed."
    },
    "speaker": {
      "type": "string",
      "description": "Full name of the speaker."
    },
    "talkTitle": {
      "type": "string",
      "description": "Main title of the talk."
    },
    "topic": {
      "type": "string",
      "description": "Primary topic or theme of the talk."
    },
    "quote": {
      "type": "string",
      "description": "A short, impactful quote from the talk."
    },
    "motivationalText": {
      "type": "string",
      "description": "A short, motivational text or message."
    },
    "aphorism": {
      "type": "string",
      "description": "A short, witty saying or proverb."
    },
    "tags": {
      "type": "array",
      "description": "A list of keywords or tags related to the talk."
    },
    "score": {
      "type": "number",
      "description": "A numerical score or rating for the talk."
    },
    "startTime": {
      "type": "string",
      "description": "Start time of the talk in ISO 8601 format."
    },
    "endTime": {
      "type": "string",
      "description": "End time of the talk in ISO 8601 format."
    },
    "talkUrl": {
      "type": "string",
      "description": "URL of the talk video or audio content."
    },
    "language": {
      "type": "string",
      "description": "Language of the talk."
    }
  }
}
```